

# 38. Критерий хи-квадрат.



Status

Completed

## Теорема Пирсона

$X \sim F$ , проверяются гипотезы как обычно.

Разобьем область возможных значений  $X_1$  на  $k$  непересекающихся промежутков  $\Delta_j$ .

$$p_j = P_{H_0}(X_1 \in \Delta_j),$$

$\nu_j$  - число наблюдений, попавших  $j$ -ый промежуток,

$$\Psi_n = \sum_{j=1}^k \frac{(\nu_j - np_j)^2}{np_j}$$

Если  $0 < p_i < 1$  при всех  $i = 1, \dots, k$ , то для любого  $y > 0$ , при верной  $H_0$

$$\Psi_n \Rightarrow \eta \sim \chi_{k-1}^2.$$

Докажем теорему Пирсона при  $k = 2$ .

В этом случае  $\nu_2 = n - \nu_1$ ,  $p_2 = 1 - p_1$ . Посмотрим на  $\rho$  и вспомним ЦПТ:

$$\begin{aligned} \rho(\mathbf{X}) &= \frac{(\nu_1 - np_1)^2}{np_1} + \frac{(\nu_2 - np_2)^2}{np_2} = \frac{(\nu_1 - np_1)^2}{np_1} + \frac{(n - \nu_1 - n(1 - p_1))^2}{n(1 - p_1)} = \\ &= \frac{(\nu_1 - np_1)^2}{np_1} + \frac{(-\nu_1 + np_1)^2}{n(1 - p_1)} = \frac{(\nu_1 - np_1)^2}{np_1(1 - p_1)} = \left( \frac{\nu_1 - np_1}{\sqrt{np_1(1 - p_1)}} \right)^2 \end{aligned}$$

Но величина  $\nu_1$  есть сумма  $n$  независимых случайных величин с распределением Бернулли  $B_{p_1}$ , и по ЦПТ

$$\frac{\nu_1 - np_1}{\sqrt{np_1(1 - p_1)}} \Rightarrow \xi,$$

где  $\xi$  имеет стандартное нормальное распределение. Поэтому

$$\rho(\mathbf{X}) = \left( \frac{\nu_1 - np_1}{\sqrt{np_1(1 - p_1)}} \right)^2 \Rightarrow \xi^2.$$

Величина  $\xi^2$  имеет  $\chi^2$ -распределение  $H_1$  с одной степенью свободы. □

## Критерий Хи-квадрат

Проверяет, что распределение выборки равно некоторому известному.

Пусть  $\vec{X} \sim F$

$$H_0 = \{F = F_0\}$$

$$H_a = \{F \neq F_0\}$$

$$\Psi_n = \sum_{j=1}^k \frac{(\nu_j - np_j)^2}{np_j}$$

$$\delta = \begin{cases} 0, & \Psi_n < c \\ 1, & \Psi_n \geq c \end{cases}$$

где  $\chi_{k-1}^2(c) = 1 - \epsilon$ .



Метод разбиения на промежутки тут не указан, но он важен! Если сделать 1 промежуток, то, понятно, критерий будет всегда срабатывать, а если слишком много — никогда. Постройте аналогию с гистограммой. Также, если распределение имеет артефакты внутри промежутков, вы это никак не узнаете, так что, по сути, проверяется немного другая гипотеза.

## Свойства

### 1. Критерий состоятельный

**Упражнение.** Вспомнить закон больших чисел и доказать, что если  $H_1'$  неверна, то найдется  $j \in \{1, \dots, k\}$  такое, что

$$\frac{(\nu_j - np_j)^2}{np_j} = \frac{n}{p_j} \left( \frac{\nu_j}{n} - p_j \right)^2 \xrightarrow{p} \infty.$$

Осталось построить критерий в соответствии с [K2](#).

Понимаем, что  $\frac{\nu_j}{n} = (I(X_1 \in \Delta_j) + \dots + I(X_n \in \Delta_j))/n \stackrel{\text{ЗБЧ}}{=} EI(X_1 \in \Delta_j) = p_j$  (при  $H_0$ ). Иначе — разность будет ненулевой, и с увеличением  $n$  как минимум одно слагаемое будет стремиться к бесконечности.

2. Критерий имеет асимптотический размер  $1 - \epsilon$ .
3. Реально допустимый уровень значимости:  $\epsilon^* = P(\eta \geq \Psi_n) = 1 - \chi_{k-1}^2(\Psi_n)$ .